

UNIVERSIDADE DO OESTE DE SANTA CATARINA – UNOESC

**ANÁLISE E CLASSIFICAÇÃO DE QUALIDADE DE VINHOS
UTILIZANDO MACHINE LEARNING E INTELIGÊNCIA
ARTIFICIAL GENERATIVA**

Aluno: Fernando Germano Klein

Disciplina: Inteligência Artificial e Sistemas Inteligentes

Professor: Jacson Matte

Chapecó – SC

2026

1 Introdução

Este trabalho unifica os conceitos de exploração de dados, aprendizado de máquina e inteligência artificial generativa, com o objetivo de construir um **agente preditivo especialista**. A partir da base de dados *Wine Quality*, são treinados e comparados diferentes algoritmos de classificação e o modelo de melhor desempenho é integrado a uma interface web e a um agente inteligente, capaz não apenas de realizar a predição, mas também de traduzir e explicar o resultado em linguagem natural ao usuário final.

Em relação ao trabalho anterior, foram aplicados novos algoritmos — incluindo o Naive Bayes — e adicionadas as etapas de back-end, integração com um modelo de linguagem (Google Gemini) e construção de uma interface interativa.

2 Descrição do Dataset

Foi utilizado o dataset *Wine Quality* (vinho tinto), composto por 1.599 amostras e 11 variáveis físico-químicas: acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico.

A variável alvo representa a qualidade do vinho, originalmente variando de 0 a 10. Para este trabalho, ela foi transformada em binária:

- **1**: vinhos com qualidade maior ou igual a 7 (bons);
- **0**: vinhos com qualidade menor que 7 (ruins).

3 Pré-processamento dos Dados

Inicialmente foi realizada a verificação de valores nulos, não sendo identificadas inconsistências. Em seguida, as variáveis foram padronizadas com o método *StandardScaler*. Diferentemente do trabalho anterior, o padronizador foi ajustado **apenas sobre o conjunto de treino** e aplicado ao conjunto de teste, evitando o vazamento de informação (*data leakage*).

Os dados foram divididos em treino (70%) e teste (30%) de forma **estratificada**, preservando a proporção entre as classes. A análise das distribuições evidenciou a presença de *outliers* em algumas variáveis; optou-se por mantê-los, pois representam características reais do dataset.

4 Análise Exploratória dos Dados

4.1 Matriz de Correlação

A matriz de correlação indicou que a variável *álcool* possui correlação positiva com a qualidade do vinho, enquanto a *acidez volátil* apresenta correlação negativa.





Figura 1: Matriz de correlação

4.2 Boxplot

Os boxplots evidenciaram a presença de *outliers* em diversas variáveis, principalmente no dióxido de enxofre total e no açúcar residual.






Figura 3: Distribuição da qualidade

5 Modelos Utilizados

Foram aplicados quatro algoritmos de classificação:

- **Regressão Linear Múltipla:** modelo de regressão cuja saída contínua é convertida em classe por meio de um limiar de 0,5;
- **KNN (K-Vizinhos Mais Próximos):** classifica cada amostra com base na classe dos vizinhos mais próximos no espaço de atributos;
- **MLP (Perceptron Multicamadas):** rede neural artificial com camadas ocultas, capaz de modelar relações não lineares;
- **Naive Bayes:** modelo probabilístico baseado no teorema de Bayes, assumindo independência entre as variáveis.

6 Ajuste de Parâmetros

Para os modelos com hiperparâmetros relevantes, utilizou-se a técnica de busca em grade (*GridSearchCV*) com validação cruzada de 5 dobras. No **KNN** foram testados o número de vizinhos e a forma de ponderação; no **MLP**, o tamanho das camadas ocultas e o termo de regularização (*alpha*). A Regressão Linear e o Naive Bayes foram treinados com sua configuração padrão. Esses ajustes contribuíram para melhorar o desempenho geral dos modelos.

7 Métricas de Avaliação

Foram utilizadas as seguintes métricas: **acurácia**, **precisão**, **sensibilidade** (*recall*) e **especificidade**. Adicionalmente, calculou-se o **F1-score** (média harmônica entre precisão e sensibilidade) como critério de desempate, por ser mais adequado a bases desbalanceadas.

8 Resultados

Modelo	Acurácia	Precisão	Sensib.	Especif.	F1
--------	----------	----------	---------	----------	----

Regressão Linear Múltipla	0.875	0.778	0.108	0.995	0.189
KNN	0.902	0.667	0.554	0.957	0.605
MLP	0.896	0.632	0.554	0.949	0.590
Naive Bayes	0.833	0.429	0.692	0.855	0.529

Tabela 1: Comparação dos modelos




Figura 4: Comparação de acurácia dos modelos

9 Discussão e Análise Crítica

O modelo **KNN** apresentou o melhor equilíbrio geral, com o maior F1-score, combinando boa acurácia e um desempenho razoável na identificação da classe minoritária. A seguir, discutem-se as vantagens e limitações de cada algoritmo testado:

- **Regressão Linear Múltipla** — *Vantagem*: simplicidade e alta especificidade. *Limitação*: por ser um modelo de regressão adaptado à classificação, obteve sensibilidade muito baixa (0,108), praticamente ignorando os vinhos bons; é a opção menos adequada para o problema.
- **KNN** — *Vantagem*: melhor F1-score e bom equilíbrio entre as métricas, sem premissas sobre a distribuição dos dados. *Limitação*: sensível à escala (mitigada pela padronização) e com custo de predição proporcional ao tamanho da base.
- **MLP** — *Vantagem*: capacidade de modelar relações não lineares, com desempenho próximo ao do KNN. *Limitação*: maior custo de treinamento, mais hiperparâmetros e risco de overfitting em bases pequenas.
- **Naive Bayes** — *Vantagem*: obteve a maior sensibilidade (0,692), sendo o melhor para detectar vinhos bons. *Limitação*: baixa precisão (muitos falsos positivos), decorrente da suposição de independência entre as variáveis, que não se sustenta neste dataset.

De modo geral, todos os modelos enfrentaram dificuldade com a classe minoritária, em razão do desbalanceamento dos dados — característica recorrente neste conjunto.

10 Arquitetura do Agente Inteligente

A solução final é composta por três camadas integradas:

1. Camada de Machine Learning. O melhor modelo, juntamente com o padronizador e os metadados (ordem das variáveis e métricas), é exportado em disco (*joblib*). Isso desacopla o treinamento da execução: o modelo é treinado uma vez e reutilizado pela aplicação.

2. Camada de Back-end e Agente. Um servidor **FastAPI** expõe as rotas `/predict` (apenas a predição) e `/analisar` (predição + explicação). As 11 variáveis de entrada são validadas com *Pydantic*. Após a predição, o resultado e os valores informados são enviados ao modelo de linguagem **Google Gemini**, guiado por um *System Prompt* que o instrui a explicar o resultado em português, de forma fundamentada e **sem alucinar** — utilizando apenas a predição e os dados fornecidos. Para garantir robustez, há tratamento de erros, tempo-limite e um modo de contingência que mantém a aplicação funcional mesmo sem acesso ao agente.

3. Camada de Front-end. Uma interface em **Streamlit** permite que o usuário informe as propriedades do vinho (ou carregue exemplos por classe) e visualize tanto o resultado bruto do modelo quanto a explicação gerada pelo agente, além dos gráficos exploratórios e da comparação entre os modelos.

Fluxo resumido: interface (Streamlit) → requisição à API (FastAPI) → modelo treinado gera a predição → agente (Gemini) traduz o resultado em linguagem natural → resposta exibida ao usuário.

11 Conclusão

Conclui-se que o modelo **KNN** foi o mais eficiente para o problema proposto, considerando o equilíbrio entre as métricas avaliadas. A integração entre o modelo de aprendizado de máquina, a API e o agente de inteligência artificial generativa mostrou-se eficaz, permitindo que o resultado matemático fosse traduzido em uma explicação clara e acessível ao usuário final.

Como trabalhos futuros, sugerem-se técnicas de balanceamento de dados (como o *SMOTE*) para melhorar a detecção da classe minoritária, além de um ajuste mais amplo de hiperparâmetros e a avaliação de modelos de *ensemble*.